基于 TinyGSM 预训练 MDLM 的 SFT 与 RL 小规模实验

1. 研究问题与主要发现

选择作业方向一：基于预训练扩散语言模型，完成监督微调（SFT）、探索适用于该模型的强化学习（RL），并在统一设置下比较模型表现。使用 TinyGSM 预训练的 MDLM checkpoint，模型日志显示约 167M 参数；SmolLM-135M 在本实验中是 tokenizer 标识，不代表训练了一个自回归 SmolLM 模型。

为解释本轮实验，将工作归纳为两个研究问题。这是报告的组织框架，不表示此前已完成正式的实验预注册。

- 问题一：对 TinyGSM 预训练 MDLM 继续进行答案区域 SFT，能否改善当前设置下的 GSM8K 表现？
- 问题二：在起点正确率较低、二元奖励较稀疏的条件下，
MDLM 上的 diffu-GRPO 适配能否带来进一步收益？

回答问题一需要比较原始模型与 SFT；回答问题二需要固定 SFT 起点、明确 RL 目标和选模规则，再比较 SFT 与 RL。训练能运行、参数会更新属于实现有效性检查，不能代替性能证据。

本轮完成了数据准备、SFT、小规模 RL、验证集选模、三种子验证及统一测试，结果如下。

模型	GSM8K 测试正确数	准确率	评估权重
原始 MDLM	73/1319	5.53%	原始 checkpoint 的 EMA
修正版 SFT	70/1319	5.31%	验证集选出的第 400 步 EMA
SFT + RL	74/1319	5.61%	验证集选出的 group016，实际更新 10 次

三者均采用 seed=1、32 步 ancestral 采样、总序列长度 512、评估 batch size=2。RL 相比 SFT 净增加 4 题，约增加 0.30 个百分点；相比原始模型净增加 1 题，约增加 0.08 个百分点。

结论限定：本轮只观察到单种子测试的轻微数值提升，没有证据表明稳定提升。 在另外三个预先指定的验证采样种子下，固定 SFT 与固定 RL checkpoint 的总正确数均为 26/384。SFT 本身也没有超过原始模型。

因此，对问题一，本轮未观察到测试正确率收益；对问题二，工程流程可用，但现有结果不足以支持稳定的性能收益。这些结论只适用于本次模型、数据规模和采样设置，不能推广为“SFT 或 RL 对 MDLM 无效”。

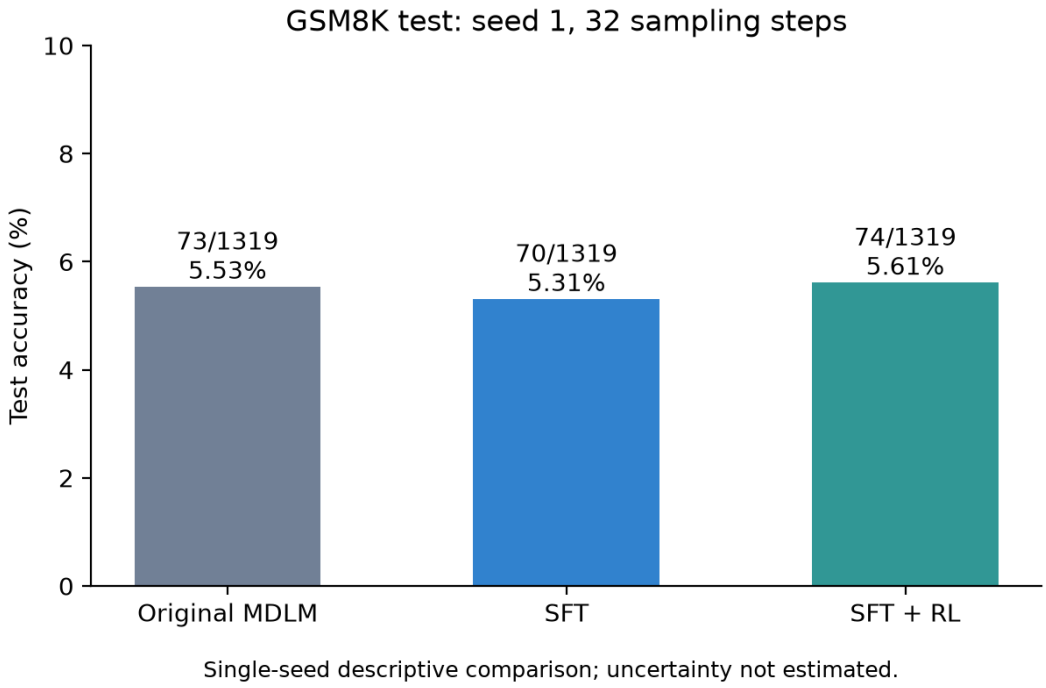


图 1 三方测试成绩

2. 模型原理与技术路线

MDLM 将离散 token 逐步替换为 mask，再学习从被遮盖的序列恢复原 token。训练可表述为带权重的 masked-language-modeling 损失；生成则从被遮盖的答案区域开始，经过多次去噪形成文本。这与逐个预测下一个 token 的自回归生成不同。MDLM 原始论文

本地配置使用 absorbing diffusion、DiT backbone、双向注意力、time_conditioning=False、loss_type=elbo。推理时固定问题前缀，只生成其后的内容；代码型回答由评分器寻找并调用 simple_math_problem()，将结果与 GSM8K 数值答案比较。

技术路线围绕数据、权重和评估条件的一致性展开：

1. 核验环境与原始模型，建立原始测试基线。
2. 从 TinyGSM 获取监督样本，完成过滤、去重、划分和哈希记录。
3. 保持问题为条件，只对答案及 EOS 区域训练，运行 SFT 并按验证 NLL 选模。
4. 从 GSM8K 训练集建立单独的 RL 训练、验证划分。
5. 先检查奖励与输入格式，再实现策略更新，最后开展固定预算 RL。
6. 固定验证集选出的 checkpoint，完成多种子验证和同口径测试。

关键设计的依据与代价

以下说明各项设置在本实验中的作用，并列出尚未验证的部分。它们是小规模试验的实现选择，不是经搜索得到的最优参数。

设计	作用或选择依据	代价与尚未回答的问题
答案区域 SFT	让问题保持为条件，将监督集中在答案代码和 EOS	未比较问题区域也参与训练的设置
生成总长度 512、采样 32 步	固定已有基线设置，使三方结果具有可比性	尚未确认长度与采样预算是否限制正确率
每题生成 8 个回答	给组内提供不同奖励的机会，同时控制生成成本	仍有 40/64 组全错；没有比较其他组大小
单步去噪概率近似	避免直接处理完整多步生成的概率计算成本	近似目标与实际多步生成奖励不完全一致
固定 SFT 参考模型与 KL 正则	在奖励更新之外限制相对起点的变化	KL 系数未消融，且约束的是近似分布
同奖励组跳过更新	奖励优势为零时不进行该组的优化计算	同时跳过 KL 更新，改变了有效更新分布
固定抽取 64 道训练题	先用受控预算观察训练与验证行为	实际只有 48 次更新，不能代表充分训练的结果

控制实验规模有助于尽早发现实现错误，但不能据此将“没有明显收益”归因为“训练量不足”。后者还需要独立的预算对照。

3. 数据划分与实验边界

实验使用单张 NVIDIA RTX 4090，在 WSL Ubuntu 的 sfm 环境中运行。完整环境版本和源码定位见附录 A；正文重点说明哪些数据用于更新、选模和最终报告。

SFT 数据

从 TinyGSM 取得 12000 条样本。过滤空内容、无效 Python 语法、缺少预期函数、超长样本，并排除规范化后完全相同的测试问题及重复问题。此次计数为：超长 16 条、重复问题 10 条，保留 11974 条；seed=42 划分为训练 10777 条、验证 1197 条。

过滤只检查格式等基本条件，没有验证所有训练程序的数学正确性。完全相同问题的排除也不能排除改写后的语义重叠。由于原模型已在 TinyGSM 上预训练，不能声称本地 SFT 验证集从未被模型见过。

修正分隔符后重新计算了长度。保留样本数和两份划分文件的哈希均未改变，因此新旧 SFT 的监督样本和划分一致。

RL 数据

使用 openai/gsm8k 的 main/train，共 7473 条。准备脚本排除与测试集、SFT 训练及验证问题的规范化完全重叠，再按固定种子划分为 RL 训练 512 条、验证 128 条、保留 6833 条。本次 7473 条均满足准备阶段条件；这不代表没有语义级重叠或预训练暴露。

正式小规模试验从 512 道 RL 训练题中按 seed=42 固定抽取 64 道。128 道 RL 验证题不参与参数更新。GSM8K 的 1319 道测试题用于报告测试结果，不用于挑选本轮 RL checkpoint。

SFT 的 1197 条验证样本用于选择 SFT checkpoint；RL 的 128 道验证题用于选择 RL checkpoint。它们不是同一套验证数据，指标也不同：前者使用验证 NLL，后者使用执行答案正确数。不能把两者的变化直接当作同一个学习指标比较。

实验为迭代开发过程：期间已经查看过原始、历史 SFT、修正版 SFT 和 RL 的测试结果，因此不能将全过程描述为完全未接触测试集的一次性盲测。上述 checkpoint 选择依据是验证指标；但既有测试结果可能影响后续研究关注点。10 月 24 日追加的 EMA 对照仅使用既有 RL 验证题，属于事后探索性诊断，不是新增独立测试证据。测试问题文本曾用于精确重叠排除，这与用测试答案更新参数或按测试分数选模应区别说明。

4. SFT 实现与结果

输入结构为 BOS、问题、配置指定的分隔符、答案代码、EOS，再补齐到 512 tokens。问题及 padding 的损失 mask 为 0，答案和 EOS 为 1。该仓库还用这一 mask 控制问题区域保持干净，避免把条件问题当作待去噪答案。

本文沿用日志中的 `val/nll` 指标名称；在当前 `loss_type=elbo` 的扩散训练设置中，它来自带权去噪损失估计，不应解释为直接计算出的完整生成序列精确负对数似然。

项目	设置
初始化	原始 `checkpoints/tinygsm/mdlm.ckpt`
更新预算	1000 个 optimizer steps
batch / 梯度累积 / 有效 batch	4 / 4 / 16
学习率 / warmup	1e-5 / 50 步
精度	bf16-mixed
验证	全部 1197 条；按既定训练批次间隔触发
选模	验证 NLL 最低
最佳 checkpoint	第 400 步，验证 NLL 0.1762108
训练 fit 耗时 / 峰值已分配显存	347.44 秒 / 6.87 GiB

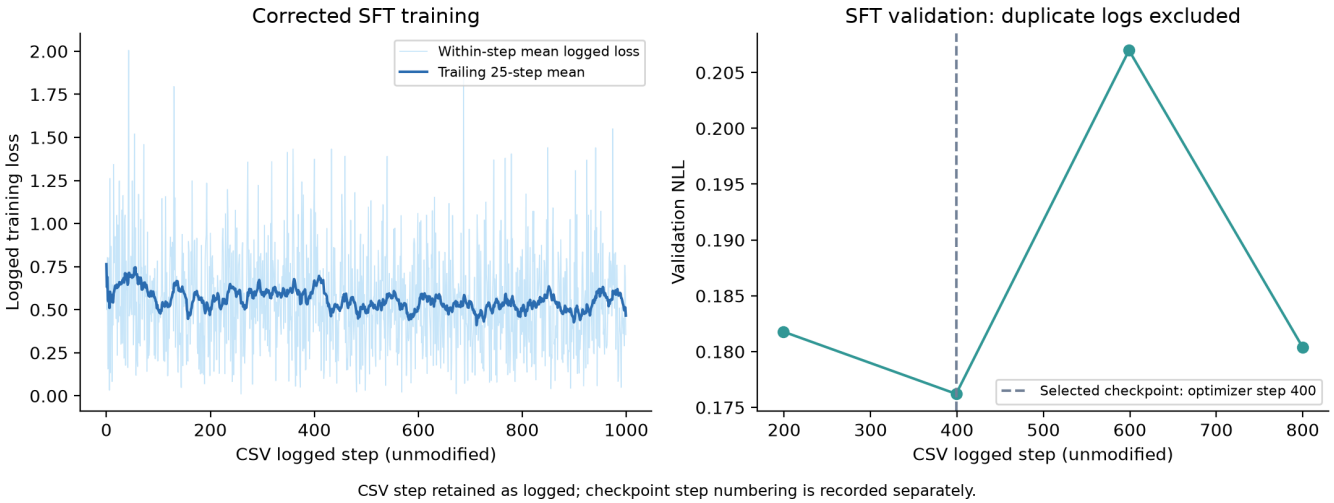


图 2 SFT 曲线修正版

图中横轴保留 CSV 原始步数。有效验证记录位于日志步数 199、399、599、800；日志步数 399 对应被选中的第 400 步 checkpoint。仓库 on_train_epoch_end 会重新写入现有验证指标，673 和 999 的记录分别重复此前值，并不代表新的验证，所以图中剔除这两点。该修正不改变选模结果。

训练损失有波动，验证 NLL 也没有单调下降。测试结果为 70/1319，低于原始模型的 73/1319。因此不能将验证 NLL 的变化直接解释为解题能力提高。

对研究问题一，当前证据只支持“这次配置下的 SFT 没有提高单种子测试正确率”。答案去噪目标与最终程序执行正确率并不相同，存在指标不一致的可能；但尚未做训练目标或数据质量对照，因此不能把它认定为此次下降的已知原因。

4.1 追加诊断：EMA 是否掩盖了普通权重的表现？

短程 SFT 使用 EMA 衰减系数 0.9999，因此提出假设：EMA 变化滞后可能掩盖普通权重的性能。先检查实现与 checkpoint，确认 EMA 更新次数从预训练的 250000 延续到 250400 和 251000，每次优化器更新后更新一次。实现的有效衰减为 min(decay, (1 + num_updates) / (10 + num_updates))；在本次计数范围内实际一直为 0.9999。按 EMA 展开式，400 和 1000 步后初始 EMA 的系数分别约为 96.08% 和 90.48%。这只是权重平均中的系数，不能解释成学习能力或知识保留比例。

固定第 400 步 checkpoint，对比其保存的普通权重与 EMA 权重。使用相同的 128 道 RL 验证题、种子 202/303/404、batch size=1、长度 512、32 步 ancestral 采样和原评分器；不训练，不使用测试集。加载后明确禁用自动 EMA 切换，并检查两套参数并非完全相同。

种子	EMA 正确数	普通权重正确数	普通权重原错变对	普通权重原对变错
202	9/128	4/128	2	7
303	8/128	5/128	2	5
404	9/128	3/128	2	8
合计	26/384（6.77%）	12/384（3.13%）	6	20

EMA 结果复现此前同种子的 SFT 验证结果。普通权重在三个采样种子下均较低，累计少 14 个正确回答。对保存回答进行静态语法诊断：

指标	EMA	普通权重
原始文本通过 ast.parse	203/384（52.86%）	156/384（40.63%）
包含预期函数名字符串	384/384	384/384
原始文本语法通过但评分错误	177	144

包含函数名只是字符串检查，不能证明函数定义有效。语法通过也不保证可执行或数学正确；这些诊断与评分器的代码提取及执行口径不同，不能据此把净少的 14 个正确回答全部归因于语法变化。

判断更新：该对照不支持通过直接停用 EMA 改善第 400 步 checkpoint 的表现，因此保留原 EMA 评测口径。它没有比较重新训练后的不同 EMA 衰减系数，也没有单独验证过拟合、灾难性遗忘或训练量不足，不能证明 0.9999 最优。三个种子复用同一批 128 道题，不是 384 道独立题或多个独立训练种子。

该次对照报告耗时 235.80 秒、峰值 allocated 显存 1.69 GiB。计时在两套模型加载与参数差异检查之后开始，覆盖采样、评分及结果写入，不含准备阶段；无新增训练。结果目录为项目下的 outputs/sft_ema_vs_raw_20261024_165836_733187。本次 12 个原始文件（含六份逐题回答和执行脚本）已归档并通过源文件与副本 SHA256 校验；逐题记录的正确数已核对，与汇总一致。语法统计仍依据执行者提供的终端输出，未在归档过程中重跑。详见 EMA 对照记录（随附材料）。

5. RL 方法：MDLM 上的 diffu-GRPO 适配

diffu-GRPO 为 masked diffusion 模型构建单步去噪概率估计：遮盖完整答案，并随机遮盖部分问题，利用一次前向得到答案 token 概率，代入组相对策略优化目标。这是近似估计，并非完整多步生成序列的精确似然。d1 / diffu-GRPO 原始论文第 3 节

本实验依据这一思想做了具体适配，而非声称完整复现论文训练配方：

- 每道题从当前策略采样 8 个回答，32 步生成，代码执行答案正确得 1，否则得 0。
- 优势为 A_i = reward_i - mean(group_rewards)，不按组标准差归一化。
- 同一组做两次内部更新；每次随机遮盖问题 token 的概率为 0.15，保护 BOS 与分隔符，完整遮盖答案区域。
- 在参数更新前缓存两个遮盖模式下的旧策略概率；当前、旧策略和参考模型比较时使用同一遮盖输入。
- 使用逐 token 概率比的裁剪目标，epsilon=0.2；学习率 1e-6，梯度范数上限 1。
- 参考模型固定为 SFT EMA。正则项为单步近似分布上的完整词表 categorical KL，系数 0.01，并按答案区域位置平均。
- 概率在 float32 中重新归一化，排除 mask token。代码沿用长度 512 的完整生成后缀，不在首个 EOS 处截断，与本次已有评分流程保持一致。
- 使用 eval() 关闭随机训练层行为，但保留策略参数梯度；这不等于禁止参数更新。参考模型则冻结参数。

实现中的最小化损失可概括为：

loss = -mean[min(ratio * A, clip(ratio, 0.8, 1.2) * A)] + 0.01 * KL

其中 ratio 是当前模型与更新前模型，在相同遮盖输入下对已采样答案 token 的近似概率之比。高于组均值的奖励产生正优势，低于组均值产生负优势；裁剪用于限制目标中的比例变化，KL 则约束相对固定参考模型的偏离。缓存旧策略概率并对齐遮盖模式，是避免把输入扰动误当成策略变化的必要检查。

这里的 ratio 和 KL 都属于单步近似模型，不能写成精确轨迹概率比或精确多步生成分布 KL。采用完整 categorical KL、MDLM 小模型、代码执行奖励和两次内部更新，均需作为本实验实现选择公开说明。

全错或全对题组的奖励优势为零，本次跳过这些题组的全部更新，包括原本可单独计算的 KL 更新。该选择降低计算量，也改变了实际优化采样分布，是方法局限之一。

权重一致性与小规模验证

初始化时将 SFT EMA 一次性复制到实际策略参数，随后禁用 EMA 切换与重新平均，避免生成用 EMA、更新却恢复另一组参数。参考模型复制自同一起点。导出时将当前 RL 参数镜像到 checkpoint 的 EMA 槽，以兼容原项目评估接口；这不是训练了新的 RL EMA。

两步更新验证检查了初始概率比为 1、初始参考 KL 为 0、奖励方向、有限且非零的梯度、参数确实变化，以及保存后重载权重逐项一致。验证成功后，正式试验重新从 SFT 起点开始，没有沿用验证产生的权重。

6. RL 小规模试验与选模

预算为 64 道训练题，每题 8 个回答，共 512 个在线回答。24 个题组有不同奖励，40 个题组全错，没有全对组，因此完成 24×2=48 次参数更新。训练前及每处理 16 道题，使用 seed=123、batch size=1、32 步采样评估相同的 128 道验证题。验证采用独立的随机数上下文，结束后恢复训练随机状态。

处理题组数	累计参数更新	验证正确数
0（SFT 起点）	0	11/128
16	10	10/128
32	26	10/128
48	36	10/128
64	48	10/128

四个 RL 候选并列，按预先设定的“并列时选最早”规则，选择 group016.ckpt。它只经过 10 次 RL 更新；48 次是整个试验的总更新数。 “最佳 RL 候选”不代表超过了 SFT 起点。

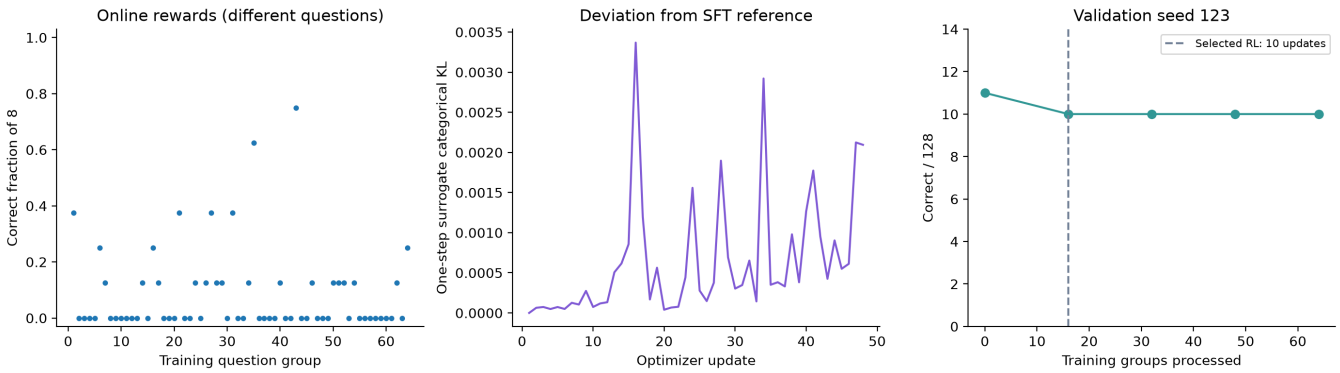


图 3 RL 曲线

梯度范数为 0.030～0.604，未达到裁剪阈值 1；单步近似 KL 最大约 0.00337；概率比超出裁剪区间的比例最高约 0.21%。这些日志没有显示数值爆炸，但也不能证明近似目标有效优化了实际正确率。每个奖励点来自不同训练题，不能把这条散点序列当作固定题集上的学习曲线。

试验总耗时 338.68 秒，包含验证和保存等工作；不是纯训练耗时。峰值已分配显存约 3.96 GiB。所有显存数字均为 PyTorch allocated 统计，并非整机 GPU 占用或 reserved 显存。

计算开销口径：SFT 的 347.44 秒来自 trainer.fit 区间，包含该区间内的训练、验证和回调开销；RL 的 338.68 秒为其试验循环区间，包含验证和保存。两者工作量与计时边界不同，不能直接用这两个数字推断训练效率高低。初始化、数据准备、历史排错和后续评测也未全部计入，因此它们不是整个项目的总 GPU 时间；尚未据此核算实际人民币成本。

7. 多种子验证与测试集逐题对照

固定 group016.ckpt 后，用新增种子 202、303、404 配对比较 SFT 与 RL，不再按这三个种子重新选择 checkpoint。

种子	SFT	RL	净变化
202	9/128	7/128	-2
303	8/128	10/128	+2
404	9/128	9/128	0
合计	26/384	26/384	0

这是同一批 128 道题的重复采样，不是 384 道独立问题，更不是新测试集。总分相同不能证明模型等效，但不支持稳定收益的说法。

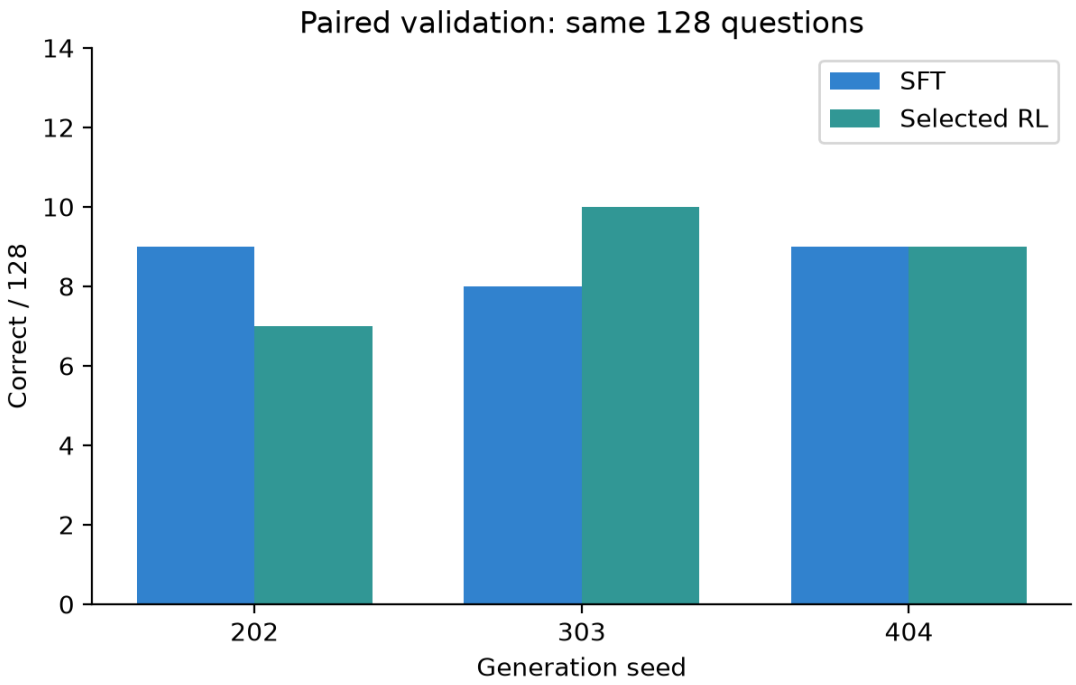


图 4 多种子验证

随后对固定 RL checkpoint 完成一次同口径测试。对三份已保存的测试回答再次使用原评分器评分，总分严格复现为 73、70、74。按相同问题和标准答案对齐后：

对比	原错变对	原对变错	净变化
原始 → SFT	5	8	-3
SFT → RL	7	3	+4
原始 → RL	6	5	+1

原始回答通过 Python 静态编译的数量分别为 716、704、721。这只检查语法；官方评分器还会提取代码、执行函数并核对数值，两者不能混为一谈。

原结果文件中的 `accuracy_se=0`、上下界等于准确率，是 `bootstrap_size=1` 时的默认记录方式，不代表估计没有不确定性。因此另做以下统计检验：

比较	不一致题（原错变对 / 原对变错）	McNemar 精确检验双侧 p
原始 → SFT	5 / 8	0.58
SFT → RL	7 / 3	0.34
原始 → RL	6 / 5	1.00

三者的 95% 正态近似置信区间分别为 4.30%-6.77%、4.10%-6.52%、4.37%-6.85%，高度重叠。三组配对差异均远未达到 0.05 显著性水平：测试集上的 -3 与 +4 题处于单种子采样波动范围内，与多种子验证持平的结果一致。作为对照，第 4.1 节 EMA 与普通权重的差异（不一致回答 20 / 6）在同一检验下 $p \approx 0.009$；但三个种子复用同一批题，配对并不完全独立，该 p 值只作参考。

8. 案例展示与错误类型

案例按测试文件顺序，各类别取前两条，完整原文见 案例文件（随附材料），并非按展示效果人工挑选。以下题号为从 0 开始的索引。

索引	现象	可以支持的解释
139	原始与 SFT 含未闭合字符串；RL 正确执行并返回 70	语法修复带来正确回答，不足以单独证明推理增强
168	SFT 使用未定义变量；RL 恢复 `2*8+2`，返回 18	RL 恢复了一道原模型已能答对的题
48	原始与 SFT 正确；RL 缺少 `piece_length` 定义	运行时错误导致退化
834	SFT 使用速度 8；RL 使用速度 0	数值设置错误导致退化
1	三个模型都计算了所需总量，却最终返回常数 10	局部计算看似合理，但返回结果错误

这些案例表明瓶颈包括语法、变量一致性、数值赋值、结果返回及数学逻辑。当前二元奖励不会区分这些失败类型。

9. 关键排错案例：从零奖励定位输入格式不一致

这一案例说明，模型输出异常时应先验证输入与执行流程，而不是直接将结果归因于模型能力或奖励稀疏。

1. 异常现象。早期自定义奖励探测得到 0/128，输出中缺少预期函数；同一旧 SFT checkpoint 通过原项目评估流程对同一批重复问题得到 11/128，且 128 个输出均包含预期函数。这提示需要比较两条输入和生成路径。

2. 先排除一个假设。本地与原 tokenizer 的词表映射及所检查的编码一致。但早期前缀对比在两侧都硬编码了同一个真实换行，未检查配置实际取值，因此不能证明真实前缀一致。

3. 进一步检查字符与 token。自定义脚本的分隔符是真实换行，字符码 [10]、token [198]；仓库 YAML 配置的单引号字符串是字面量反斜杠+n，字符码 [92,110]、token [76,94]。词表相同，拼接输入仍然不同。

4. 固定 checkpoint 做针对性修复。探测脚本改为读取配置中的分隔符，其他既定探测设置保留，得到 14/128；没有更新模型参数。它与原项目流程的 11/128 不要求逐题一致，因为两条生成流程尚未逐项完全对齐。

5. 修复受影响的训练流程。同样的问题存在于自定义 SFT 脚本，因此重新准备数据并从原始模型重跑 SFT。数据划分哈希未变；新 SFT 的奖励探测为 12/128，有 7 个混合奖励组。

修复确认的是输入一致性和奖励流程可用，不是性能提升。修正版 SFT 的测试成绩为 70/1319；此前分隔符不一致的旧版 SFT 曾为 75/1319。旧结果作为历史记录保留，不因分数较高而纳入修正后的主对照。错误来自本地自定义脚本，不归因于仓库。

这次排错的可复用经验是：不能只检查 tokenizer 名称或词表；还应记录实际字符串、特殊 token、分隔符 token IDs 和最终前缀。环境安装等其他问题汇总在附录 B。

10. 结果解释、局限与后续研究

10.1 为什么三个模型的准确率都较低？

首先，原始模型在相同测试设置下也是 5.53%，因此低分并非全部由后续 SFT 或 RL 造成。其次，1319 个原始回答中，仅 716、704、721 个分别通过原始文本的 Python 静态编译，说明输出格式确实是需要关注的环节；案例还出现未定义变量、错误数值和错误返回结果。

不过，原始文本编译检查与官方代码提取、执行评分的口径不同，不能直接把未通过编译的数量当作全部语法失败数，也不能据此计算其对准确率的因果贡献。本轮没有做完整失败分类或采样预算对照，所以不能认定低分主要由模型规模、数据质量、32 步采样预算中的某一个因素造成。

10.2 区分观察事实、解释与待检验假设

层次	当前可以写出的内容
观察事实	SFT 测试从 73 降至 70；选定 RL 候选从 70 增至 74；新增三个验证种子下，SFT 与 RL 均为 26/384；同一 SFT checkpoint 的 EMA / 普通权重验证正确数为 26 / 12，原始文本语法通过数为 203 / 156
受证据支持的解释	本轮没有显示稳定收益；具体输出同时出现改善与退化；参数和梯度检查通过，但不足以证明优化目标提升实际正确率
待检验假设	稀疏奖励、小规模更新、训练数据质量及单步概率近似可能影响收益，尚未通过消融区分
当前不能声称	RL 显著提升推理能力；SFT/RL 对 MDLM 无效；分隔符修复保证更高分；梯度稳定说明方法没有局限；EMA 滞后已被证明导致低分或当前 EMA 系数最优

40/64 组全错意味着本次规则下这些组没有带来参数更新，这是可观测事实。但“这些组导致了没有收益”仍是因果假设。类似地，低近似 KL 不保证采样回答不变，也不说明近似分布与真实生成分布足够接近。

10.3 主要局限

本轮只用 64 道 RL 训练题、共更新 48 次，且最终测试的是其中第 10 次更新后的权重，不能代表充分训练。没有 RL-only、组大小、KL 系数、训练预算等对照。SFT 数据未全面核验数学质量，预训练暴露未知；验证集也较小，并承担了选模功能。

新增采样种子仍使用同一批验证问题，不能替代独立验证集。主测试只使用一个生成种子；配对检验显示三组测试差异均不显著（$p \geq 0.34$），检测更小差异需要更多种子或更大测试集。单步近似目标、跳过同奖励组及完整后缀损失范围都是需要进一步研究的实现选择。

10.4 一项具体的后续实验计划（尚未执行）

优先检验一个范围明确的问题：当前 32 步采样预算是否限制了固定模型的表现？这比同时修改学习率、训练量和奖励更容易解释。

计划固定本报告的 SFT 和 group016 两个 checkpoint，在同一批 128 道验证题、相同种子 202/303/404、batch size=1、长度 512 和相同评分规则下，仅比较 32 与 64 步 ancestral 采样，构成“两个模型 × 两种采样步数”的对照。记录每个种子的正确数、逐题得失、生成耗时和格式诊断；对照前先冻结设置，不据中间分数追加候选条件。

若两个模型都改善，可支持“采样预算在该验证设置下影响表现”，但不能证明这是总体低分的唯一原因，也不能把它算作 RL 的训练收益。若只有两模型差值发生变化，需要报告采样设置与模型的交互，而不是只展示最有利组合。若没有改善，也只限制这一组实验条件下的假设。

该计划不使用测试集决定设置，尚未产生任何新结果，也不能替代训练方法消融。

10.5 本轮结论

- 工程成果：完成数据处理、SFT、MDLM 上的 RL 适配、更新检查、权重导出和统一评分，并保留可审计记录。
- 实验发现：本轮 SFT 未超过原模型；选定 RL 候选仅有单种子测试上的轻微净收益，多种子验证平均持平。输出改善与退化均涉及代码和数值逻辑。
- 尚未完成：证明稳定性能收益、量化主要失败原因、训练方法消融及全新环境复现。

退出码、导入成功、参数变化和损失下降各自只提供局部证据。本轮工作的价值在于把这些检查与最终表现分开报告，并明确哪些判断已经得到支持、哪些仍需实验。

11. 交付范围与来源

- 本文与 运行说明（随附材料）：方法、操作入口、实际完成范围和复现边界。
- figures/：已核验的四组图，提供 PNG 与 PDF；SFT 使用修正版。
- evidence/：成绩、逐题表、案例、配置、方法说明、依赖记录和修正审计。
- 项目源码/（提交包根目录下）：完整项目源码、实验数据、选定的 SFT / RL 权重和三份完整测试回答；各文件的 SHA256 见 文件校验清单.json。

原始 MDLM 为公开权重，未重复打包；中间 checkpoint 与 optimizer 状态也未打包。效果展示采用已保存的具体案例（见第 8 节）。

方法与项目来源：MDLM 论文、d1 / diffu-GRPO 论文、s-flm 仓库、模型仓库、TinyGSM 数据集。

AI 辅助工具使用声明：本实验新增的数据处理、训练与分析脚本在编写和排错过程中使用了 AI 编程助手。实验设计、全部训练与评测的运行、结果核对及结论判断均由本人完成，本人能够解释报告中的方法、代码与结果。

附录 A：环境与源码定位

实验在 Windows 的 WSL Ubuntu 环境中运行，GPU 为 NVIDIA RTX 4090，nvidia-smi 报告总显存 23028 MiB。Conda 环境为 sfm，Python 3.12.15。实验保存的仓库提交号为 30def79976ca3b1cdcb5fcbfa0165524e44001de。

依赖	已核验版本
PyTorch / torchvision	2.7.0+cu126 / 0.22.0+cu126
Lightning	2.5.1
transformers / datasets	4.45.0 / 3.5.0
NumPy / PyArrow	1.26.4 / 19.0.1
Hydra / Triton	1.3.2 / 3.3.0

历史 GPU 运算检查确认 FlashAttention 2.8.3 可用。详细依赖见 evidence/sft_environment-lock.txt。提交号不能覆盖未提交的本地代码，完整代码以提交包 项目源码/ 为准；迁移限制见运行说明。

附录 B：其他排错与无效尝试

阶段	观察证据	处理与结论边界
PyArrow 导入	pip check 通过，但导入报 NumPy 版本不满足	调整到 NumPy 1.26.4 / PyArrow 19.0.1 后导入通过；依赖元数据检查不等于二进制导入检查
FlashAttention	模块缺失	安装匹配 Python、Torch、CUDA 和 ABI 的 2.8.3 wheel；GPU attention 与项目导入检查通过
Triton	找不到 C 编译器	安装编译工具并设置 CC/CXX 后运行成功；未以安装完整 nvcc 作为已完成步骤
数据下载退出	保存后出现 PyGILState_Release，退出 134	禁用 tokenizer 并行未可靠解决；独立核对 JSON、条数、字段和 SHA256 后使用已保存数据，底层退出异常根因未证实
数据脚本	曾缺少文件；也曾存在仅 4 字节的占位文件，退出 0	后续核对实际代码与输出，不能只依赖退出码认定数据处理成功
图表验证点	epoch 末再次记录现有指标	查看日志钩子确认后剔除重复点；原图、原日志与修正审计均保留